

AFYA CENTRO UNIVERSITÁRIO – ITAPERUNA/RJ

ENGENHARIA DA COMPUTAÇÃO

DISCIPLINA: INTRODUÇÃO À INTELIGÊNCIA ARTIFICIAL

REDES NEURAIS ARTIFICIAIS: TIPOS DE REDES, FUNÇÕES DE ATIVAÇÃO, HIPERPARÂMETROS, TREINAMENTO E APLICAÇÕES

SAMUEL VALENTIM DE SOUZA

PROFESSOR: MAEZIO PEREIRA DA
SILVA

ESPERA FELIZ – MG / ITAPERUNA – RJ

16/04/2026

1 - Introdução

No início, os computadores eram usados para cálculos matemáticos simples e repetitivos, como nas primeiras máquinas desenvolvidas no mundo durante o século XX. Entretanto, com o decorrer das décadas e o avanço tecnológico crescente, houve um aumento expressivo na demanda pelos computadores, nas quais os computadores eram submetidos a tarefas mais complexas que cálculos matemáticos simples, um exemplo é com a implementação da automatização da indústria com fim de ganhar tempo e economizar recursos. Com isso, as máquinas começaram a ser usadas para o processamento de dados, automação industrial e, "recentemente", interagir com a linguagem natural, ou seja, comunicação entre humanos e máquinas.

Foi então que os pesquisadores começaram a buscar formas de simular a inteligência humana através das máquinas, que deveriam aprender, pensar, tomar decisões e reconhecer padrões. Desse modo, o desenvolvimento do poder computacional foi acelerado através de algoritmos e do grande fluxo de dados disponíveis para uso.

Nessa perspectiva, inspiradas no funcionamento do cérebro humano, foram criadas as Redes Neurais Artificiais (RNAs). Com finalidade de replicar digitalmente, o comportamento dos neurônios biológicos responsáveis por receber, processar e transmitir informações. Logo, foi através de modelos matemáticos que conseguiram aprender a partir de exemplos (como ensinar ao algoritmo que o operador "+" soma dois numeros) e o desenvolvimento do seu desempenho ao longo do tempo, que os pesquisadores criaram as RNAs.

Essas redes possibilitam que problemas complexos, que seriam extremamente difíceis de resolver ou até mesmo impossíveis através da programação tradicional que segue regras fixas, possam ser resolvidos com certa simplicidade. Logo, as Redes Neurais Artificiais têm um papel essencial no desenvolvimento da Inteligência Artificial, que atualmente é capaz de até mesmo reconhecer padrões, processamento da linguagem natural e visão computacional.


Dessa forma, este artigo de revisão irá apresentar os conceitos fundamentais sobre as redes neurais artificiais, apresentando a sua arquitetura, funções de ativação e o que desafia o seu treinamento. Além disso, o trabalho irá discutir sobre como essa tecnologia pode ser aplicada em diferentes áreas e analisar seus limites atuais.

2 - Fundamentação Teórica

2.1 - O Neurônio Biológico como Inspiração

O neurônio biológico possui uma estrutura específica e tem funções bem definidas: Os **dendritos**, que recebem sinais químicos de outros neurônios; o **corpo celular**, responsável por processar esses sinais e avaliar se o estímulo que foi recebido é intenso; e por último o **axônio**, que transmite o pulso elétrico para as outras células, desse modo, propagando a informação pelo sistema nervoso inteiro. Sob essa perspectiva, o desenvolvimento das Redes Neurais Artificiais mostram que tem como a principal inspiração o funcionamento do cérebro humano, que é composto por bilhões desses neurônios interligados, que realizam o processo e transmissão de informações, em outras palavras, realizam o "fluxo de dados" da mente humana. Esse conjunto de neurônios serviu como base para que o desenvolvimento de sistemas artificiais pudesse ser capaz de simular o comportamento inteligente

Figura 1 - Estrutura do Neurônio Biológico




Fonte: Borges et al. (2015)

2.2 o Modelo Matemático: Neurônio Artificial

A partir do neurônio biológico, foi desenvolvido o neurônio artificial, o qual teve como primeira formulação o **modelo de Perceptron**. Esse modelo tem como objetivo representar matematicamente como o neurônio biológico comporta, através de operações computacionais

Figura 2 - Estrutura do Neurônio Artificial



Fonte: (SOARES; SILVA, 2011).

Ao analisar a figura 2, temos as **entradas** (x) que representam os dados recebidos pelo sistema, enquanto os **pesos** (w) são a intensidade das conexões, responsáveis por armazenar o conhecimento adquirido pela rede. Esses valores são combinados por meio de um somatório, que multiplica cada entrada por seu respectivo peso e após isso uma soma ponderada. Desse modo, o resultado desse processo deve ser submetido a uma **função de ativação**, que irá determinar se o neurônio será ou não ativado, simulando o disparo do neurônio biológico.

A modelagem matemática de um neurônio artificial é dado pela equação:

$$y = \Theta \left(\sum_{j=1}^d w_j x_j - \mu \right)$$


O valor final desse somatório, após ser ajustado pelo viés, deve passar por uma função de ativação que irá definir a **saída final** (y). Esse processo é individual, pode até parecer simples, mas quando seu neurônio é organizado de forma coletiva, sua complexidade aumenta consideravelmente.

2.3- Arquitetura em camadas

Os neurônios artificiais são a unidade básica de processamento, ou seja, seu potencial se torna limitado caso seja usado isolado. Desse modo, ao organizar os neurônios em estruturas conhecidas como redes neurais, criadas a partir de múltiplas camadas interligadas, estamos aumentando o potencial deles.

A camada de entrada é quem recebe os dados brutos do problema, como os pixels de uma imagem ou valores numéricos de um conjunto de dados. Nesse rumo, os dados são processados pelas camadas ocultas (*hidden layers*), lugar onde acontece a extração das características relevantes e a modelagem das relações complexas entre as informações. Por último, temos a camada de saída, que basicamente nos mostra o resultado final da rede, podendo ser uma classificação ou previsão. Para uma rede, quanto maior a quantidade de camadas e neurônios, maior será a capacidade de representar padrões complexos e captar relações não lineares, tornando-as então, fundamentais nas aplicações modernas da Inteligência Artificial.

Figura 3 - Rede de propagação direta



Fonte: (SILVA et al., 2022).

Segundo a figura 3, podemos ver que a rede neural baseia o seu processamento em uma hierarquia funcional, onde cada camada tem um papel específico na transformação do sinal.

As camadas de entrada são a interface que recebem os estímulos externos ou dados brutos do problema; As camadas ocultas são quem extrai os padrões e modela as relações não lineares e, que, quanto mais camadas ter, maior será a capacidade de aprendizado do sistema; Por último, a Camada de saída é quem conclui o fluxo de informação e traduz todo o processo em uma classificação ou previsão.

3 - Tipos de Redes Neurais Artificiais.

O modelo clássico de propagação direta ou *Feedforward* é a base da arquitetura das redes neurais, com isso, foram desenvolvidas novas estruturas para poder lidar com diferentes tipos de problemas. Logo, essas redes podem ser classificadas de acordo com o fluxo de dados das suas camadas e principalmente, pela sua arquitetura.

A Tabela 1 abaixo apresenta uma comparação entre as principais arquiteturas atuais:


Tabela 1 - Comparativo entre Arquiteturas de Redes Neurais

TIPO DE REDE:	Sigla:	Característica Principal:	Aplicação Típica:
Multicamadas	MLP	Fluxo unidirecional de dados em camadas interligadas.	Classificação simples e regressão.
Convolucionais	CNN	Especializada no processo de dados com grade topológica.	Visão computacional e reconhecimento de imagens
Recorrentes	RNN	Possui conexões de retroalimentação que geram “memória”.	Processamento de Linguagem Natural e séries temporais

Fonte: Elaborada por Samuel Valentim (2026)

As arquiteturas detalhadas na tabela 1 mostram como as RNAs evoluíram para diferentes domínios. Enquanto as **Multicamadas** (MLP) introduzem a base da classificação linear não linear, as **Convolucionais** (CNN) estabelecem camadas de filtragem essenciais para a visão computacional, e as **Recorrentes** (RNN) são responsáveis pelo processamento de sequências temporais por ciclos de retroalimentação. Seu uso depende do tipo de dados de entrada e da complexidade da tarefa exigida.

Figura 4 - Rede Neural Recorrente



Fonte: (BARBOSA et al., 2021).

Diferente do modelo visto na figura 3, a figura 4 mostra como as conexões recorrentes permitem que a rede mantenha o funcionamento da arquitetura interna como uma memória de curto prazo.

4 - Funções de Ativação

As funções de ativação são fundamentais em uma rede neural, pois através delas, são decididos se a entrada de um neurônio deve ser “disparada” como um sinal de saída para a camada seguinte. Sem as funções, as redes iriam se comportar como uma função linear que é incapaz de aprender padrões complexos como imagens ou voz. Desse modo, seu valor se encontra na introdução da não-linearidade ao modelo matemático.

Abaixo, a Tabela 2 descreve as 4 funções de ativação mais usadas em redes neurais:

Tabela 2 - Comparativo de Funções de ativação

Função:	Comportamento Matemático:	Vantagem Principal:	Limitação / Risco:
Degrau (step):	Saída binária (0 ou 1) baseada na limiar (μ).	Extremamente simples para problemas básicos.	Não permite o uso de algoritmos não derivados.
Sigmoide:	Mapeia os valores no intervalo entre 0 e 1.	Suavidade na transição, indicado para probabilidade de saída.	O aprendizado pode ficar muito lento (<i>Vanishing Gradient</i>).
Tangente Hiperbólica (Tanh):	Mapeia os valores entre -1 e 1.	Saída focada em zero, acelerando a convergência do treino.	Sofre com saturação do gradiente em valores extremos.
ReLU:	Mantém valores positivos e zera os negativos.	Alta eficiência computacional e evita o desaparecimento do gradiente.	Pode gerar “neurônios mortos” se existirem muitos valores negativos.

Fonte: Elaborado por Samuel Valentim (2026)

A escolha da função de ativação depende da posição da camada na rede. Desse modo, atualmente, a **ReLU** é a preferida para as camadas ocultas por conta de sua eficiência no processamento de grandes fluxos de dados. Já a função **Sigmoide** é reservada para a camada de saída quando houver problemas de classificação binária.

5 - Hiperparâmetros

Os Hiperparâmetros são o conjunto de variáveis de estruturas que controlam outras estruturas, ditando como a rede deve aprender, estabelecendo a estratégia que será usada para buscar uma precisão adequada, ou seja, eles não são “pegos” pela rede, mas sim escolhidos pelo projetista a fim de moldar o treinamento e a complexidade do modelo. Diferente do aprendizado biológico humano, no qual os processos de ajuste ocorrem de forma natural do viver e aprender.

De acordo com Reis (2021), a maior parte dos algoritmos de aprendizado de máquina é dependente de hiperparâmetros, que são, basicamente, configurações externas usadas para o controle do comportamento do sistema. Já os parâmetros internos, que são estimados a partir dos dados existentes, como os pesos da rede. Nesse contexto, podemos definir os hiperparâmetros como variáveis pré-definidas que definem a estrutura do modelo e o tipo de treinamento.

Conforme a síntese mostrada pelo autor, temos como principais elementos de ajuste:

- **Arquitetura do Modelo:** Analisa o número de camadas ocultas e de neurônios. Várias camadas permitem um melhor aprendizado, entretanto, quanto maior o número, mais técnicas de regularização serão exigidas para evitar uma possível falta de adequação.
- **Processo de Otimização:** Nesse processo, a taxa de aprendizagem é fundamental, pois se configurada errada, pode gerar uma baixa eficiência do modelo. O uso do **Momentum** (entre 0,5 e 0,9) ajuda o caminho dos ajustes com base nos passos antigos, evitando oscilações.
- **Técnicas de Regularização:** O **Dropout** é uma ferramenta indicada para ter um melhor desempenho, desativando de forma aleatória, de 20% a 50% dos neurônios, a fim de que a rede aprenda representações sozinha.
- **Controle de Fluxo:** O número de épocas e o tamanho do Batch (geralmente em potências de 2, como 32, 64 e 128) são quem definem a frequência que os dados são exibidos e tem seus parâmetros atualizados.

Reis (2021) determina que, como os valores não são ajustados automaticamente pelo modelo, o projetista deve realizar experimentos ou usar algoritmos auxiliares para encontrar uma combinação ideal que solucione o problema proposto.

6 - Treinamento, Backpropagation e Overfitting


O treinamento de uma Rede Neural Artificial é um processo de ajuste de parâmetros (pesos e vieses) que tem como objetivo, minimizar o erro entre a saída possível e a saída real. Esse processo necessita ser guiado por uma **Função de Perda**, que quantifica a imprecisão do modelo. Dessa forma, quanto menor o valor da função de perda, mais próximo o modelo está da solução adequada.

A “inteligência” do aprendizado da rede se forma no algoritmo de **Backpropagation** (retropropagação). Após as entradas percorrerem a rede (*Forward Pass*), o erro deve ser calculado na saída e direcionado para à camada de entrada novamente. Com o uso do Gradiente Descendente, a rede consegue calcular a contribuição de cada neurônio no erro total e ajusta automaticamente os

pesos através da Taxa de Aprendizagem, definindo a escala dos ajustes. (REIS, 2021).

Sobre essa perspectiva, um dos maiores desafios do treinamento é o **Overfitting** (sobreajuste), que nada mais é do que a perda da capacidade de adaptar novos dados. Isso ocorre quando a rede se torna complexa e acaba “memorizando” os dados de treino e seus erros.

Figura 5 - Cenários de Aprendizagem da Máquina



Fonte: Adaptado de Data Hacker (2021)

Ao analisar a figura 5, percebemos que o cenário ideal para uma rede neural é o modelo **Optimal**, onde a curva de decisão é suave o suficiente para ignorar ruídos mas também é precisa para classificar os dados corretamente. Quando essa rede atinge o cenário de **Overfitting**, ela praticamente perde sua utilidade prática, pois será incapaz de lidar com dados reais em um ambiente que não seja o de teste.

Desse modo, para solucionar esse problema e direcionar a rede para um modelo adequado, são usadas as estratégias antes discutidas (REIS, 2021):

- **Dropout:** Com a desativação de neurônios aleatórios, impedimos que a rede crie uma dependência excessiva em algum caminho específico, evitando a memorização.
- **Early Stopping:** Para o treinamento assim em que o erro de validação não cai mais, para evitar que o número de épocas seja alto.
- **Taxa de Aprendizagem:** Garante que os ajustes nos pesos sejam ajustados para que possam encontrar o mínimo global da função de perda sem uma oscilação exagerada.

7 - Aplicações Práticas

As Redes Neurais Artificiais (RNAs) são fundamentais para que possamos resolver problemas de alta complexidade onde os algoritmos lineares simples não conseguem solucionar.

Abaixo, analisa-se duas aplicações reais, indicando também uma arquitetura adequada para seu processamento:

7.1 - Diagnóstico Auxiliado por Computador

- **Problema:** A detecção precoce de patologias em exames de imagem (como Raio-X ou Ressonância Magnética) necessita uma análise de padrões visuais extremamente sutis, onde o erro humano por cansaço pode ser um risco.
- **Solução:** Uso da Rede Neural Convolucional (CNNs). Esse tipo de rede é a mais indicada para filtrar e extrair características espaciais, podendo identificar nódulos ou irregularidades em tecidos com uma precisão melhor ou complementar a análise da clínica convencional.

7.2 - Previsão de Séries Temporais no Mercado Financeiro

- **Problema:** Conseguir antecipar a flutuação de ativos financeiros ou detectar possíveis fraudes em tempo real necessita um sistema que entenda não só o dado atual, mas também o contexto dos eventos anteriores.
- **Solução:** A Rede Neural Recorrente (RNNs). Como visto na figura 4, as RNNs tem um ciclo de retroalimentação que funciona como uma memória temporária. Isso permite que a rede “lembre” do comportamento passado do mercado e possa prever tendências futuras ou até mesmo identificar possíveis desvios bruscos que possam resultar em transações fraudulentas.

8 - Vantagens e Limitações

A aplicação de Redes Neurais Artificiais trouxe e traz avanços significativos para a computação moderna, entretanto, é necessário adequar suas capacidades para garantir uma resolução dos seus respectivos desafios operacionais.

8.1 - Vantagens

A principal vantagem é seu aprendizado adaptativo, que permite aprender e realizar tarefas com base em dados de treinamento, sem a necessidade de regras de programação para cada cenário.

Por conta de sua natureza distribuída, o dano parcial que alguns neurônios podem sofrer não interrompe o funcionamento da rede, permitindo que ele continue operando mesmo com falhas, revelando uma tolerância a falhas.

Além disso, também tem um processamento não-linear, o que o permite captar relações complexas entre variáveis, característica que é fundamental no processo de dados do mundo real, como áudios e vídeos.

8.2 - Limitações

Por ter uma natureza de “Caixa Preta”, entrega uma falta de aplicabilidade, sendo extremamente difícil entender o caminho lógico que a rede percorre até tomar uma decisão, limitando o seu uso em áreas arriscadas como medicina diagnóstica crítica e o direito.

Além disso, também exige dados e processamento, ou seja, as RNAs dependem de um alto fluxo de dados para evitar o *overfitting* e desempenhar um alto poder computacional, deixando o projeto caro e energeticamente ineficiente.

Por último, tem uma dependência em hiperparâmetros, como apresentado por Reis (2021), seu desempenho pode ser extremamente sensível a ajustes manuais, na qual, uma única escolha errada na taxa de aprendizagem ou no *dropout* pode estragar todo o processo de treinamento.

9 - Conclusão

Este trabalho possibilitou a análise sobre como funciona e como é estruturada uma Rede Neural Artificial (RNA). Onde começamos pela reprodução do neurônio biológico, observando como a matemática dos pesos, somatórios e funções transformam sinais de entrada em decisões complexas, que permitem que máquinas possam realizar tarefas de classificação e predição com um grau de autonomia alto.

A síntese do aprendizado que construí mostra que a eficiência de uma rede não está apenas na sua arquitetura (número de camadas e neurônios), mas sim no ajuste fino de seus hiperparâmetros. Desse modo, o equilíbrio entre a taxa de aprendizagem, o uso de *dropout* e o controle do número de épocas se mostrou essencial para evitar o *overfitting*, garantindo dessa forma que o modelo não só memorize os dados mas também desenvolva a capacidade de generalização necessária para as aplicações reais, como a visão computacional ou mercado financeiro mencionados artes

Portanto, mesmo que as RNAs mostrem limitações quanto à sua aplicabilidade das decisões e à alta necessidade de recursos computacionais, seu alto índice de possíveis usos permite que seja o principal pilar da Inteligência Artificial moderna. Logo, o domínio sobre o processo de treinamento e a compreensão rigorosa de suas vantagens e riscos é fundamental para que possamos desenvolver soluções confiáveis.

Referências

- BARRETO, J. M. **Introdução às Redes Neurais Artificiais**. Florianópolis: UFSC, 2015. Disponível em: <http://www.inf.ufsc.br/~j.barreto/tutoriais/Survey.pdf>. Acesso em: 18 abr. 2026.
- DATA HACKER. **Popular techniques to prevent the overfitting in a neural networks**. 2021. Disponível em: <https://datahacker.rs/018-pytorch-popular-techniques-to-prevent-the-overfitting-in-a-neural-networks/>. Acesso em: 19 abr. 2026.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. MIT Press, 2016. Disponível em: <http://www.deeplearningbook.org>.
- HAYKIN, S. **Redes Neurais: Princípios e Prática**. 2. ed. Porto Alegre: Bookman, 2001.
- PAIXÃO, J. L. **Redes Neurais Artificiais: estrutura, modelagem matemática e exemplo de aplicação**. In: Inovações Multidisciplinares na Engenharia. [S.l.]: ResearchGate, 2024. Disponível em: <https://www.researchgate.net/publication/391070692>. Acesso em: 18 abr. 2026.
- REIS, Carlos Henrique. **Otimização de Hiperparâmetros em Redes Neurais Profundas**. 2021. Monografia (Bacharelado em Ciência da Computação) – Universidade Federal de Itajubá - UNIFEI, Itajubá, 2021.